

向量数据库是 RAG 系统的核心组件，用于高效存储和检索嵌入向量。在典型的 RAG 架构中，文档首先被分割成较小的 chunk，然后通过嵌入模型转换为高维向量，最后存储在向量数据库中。当用户提出查询时，查询文本同样被转换为向量，然后通过近似最近邻搜索在向量库中找到最相关的文档片段。

常见的向量数据库包括 Pinecone、Weaviate、Qdrant 和 ChromaDB。每种数据库都有其特点：Pinecone 是托管的云服务，适合生产环境；Weaviate 支持多模态搜索；Qdrant 专注于高性能；ChromaDB 则轻量且易于本地部署。

RAG 系统的检索质量取决于多个因素：chunk 大小、重叠窗口、嵌入模型选择、检索策略等。较小的 chunk（如 256 tokens）适合精确匹配，但可能丢失上下文；较大的 chunk（如 1024 tokens）保留更多上下文，但可能包含无关信息。通常建议使用 200-500 tokens 的 chunk 大小，并设置 10-20% 的重叠。